



**Universitat**  
de les Illes Balears

## **TRABAJO DE FIN DE MÁSTER**

### **LAIA@ESTUDIOS EXPLORATORIOS: APLICABILIDAD DE LLM PARA LA EVALUACIÓN DIDÁCTICA GENERATIVA**

**Ramon Saleta-Piersanti Besga**

**Máster Universitario en Sistemas Inteligentes (MUSI)  
Especialización en Inteligencia Artificial Aplicada.**

**Centro de Estudios de Postgrado**

**Año académico 2024/25**

# **LAIA@ESTUDIOS EXPLORATORIOS: APLICABILIDAD DE LLM PARA LA EVALUACIÓN DIDÁCTICA GENERATIVA**

**Ramon Saleta-Piersanti Besga**

**TRABAJO DE FIN DE MÁSTER**

**Centro de Estudios de Postgrado**

**Universidad de las Islas Baleares**

**Año académico 2024/25**

**Palabras clave:**

**LLM, Embeddings, RAG**

***Tutor(s): Isaac Lera y Carlos Guerrero.***

# LAIA@Estudios exploratorios: Aplicabilidad de LLM para la Evaluación Didáctica Generativa

Ramon Saleta-Piersanti Besga

**Tutor:** Isaac Lera y Carlos Guerrero

Trabajo de fin de Máster Universitario en Sistemas Inteligentes (MUSI)

Universidad de las Islas Baleares, 07122 Palma, Islas Baleares, España

ramon.spiersanti2@estudiant.uib.cat

**Resumen**—This work explores the feasibility of using Large Language Models (LLMs) in combination with Retrieval-Augmented Generation (RAG) architectures through a systematic experimental study. A benchmark of 10 gold-standard questions was created using synopses from the first season of *The Simpsons*, allowing controlled evaluation mixing three LLMs (Llama3, Mistral, DeepSeek-R1), three embedding models (nomic-embed-text, all-minilm, mxbai-embed-large), and three languages (Catalan, Spanish, English). More than 250 response instances were analyzed using both qualitative metrics (Gold Tests, groundedness) and quantitative ones (latency, token efficiency).

Among the tested models, Llama3 offered the most balanced trade-off between accuracy and efficiency, while nomic-embed-text emerged as the most robust embedding, particularly in Romance languages. Spanish achieved higher lexical similarity scores, whereas Catalan was rated more positively in qualitative evaluations. These findings provide empirical evidence of the potential of RAG-based systems and contribute to understanding their behavior under different experimental settings.

## I. INTRODUCCIÓN

El desarrollo tecnológico de las últimas décadas ha transformado de manera radical la forma en que accedemos a la información y utilizamos las herramientas digitales. Quienes crecimos en los años noventa fuimos testigos del paso de las enciclopedias impresas a recursos digitales como *Encarta* y, poco después, *Wikipedia*. De manera análoga, la evolución del software de ofimática muestra un salto significativo: de simples procesadores de texto a sistemas capaces de ofrecer corrección automática y control de versiones. Estos ejemplos ilustran un fenómeno más amplio, el avance tecnológico se acelera de manera continua y cada innovación abre nuevas posibilidades de uso.

Un hito ilustrativo de esta aceleración se produjo en 2016, cuando AlphaGo, desarrollado por DeepMind, logró vencer al campeón mundial de Go en un histórico 3-2 [22]. Este acontecimiento suscitó una reflexión recurrente: ¿hasta dónde será capaz de llegar la inteligencia artificial en un futuro próximo?

En la actualidad asistimos a una auténtica proliferación de aplicaciones basadas en inteligencia artificial, en particular de los denominados grandes modelos de lenguaje (LLM). Desde la popularización de *ChatGPT* hasta el auge de *Gemini* o *DeepSeek*, el campo de la IA generativa se ha consolidado como un área de investigación y desarrollo de enorme dinamismo, aunque todavía con muchos desafíos por explorar.

Este contexto motiva el presente Trabajo de Fin de Máster, cuyo propósito es analizar y evaluar el funcionamiento de la arquitectura *Retrieval-Augmented Generation* (RAG), un enfoque que combina la recuperación de información externa con la generación de texto, en un escenario experimental. Para ello se ha desarrollado un prototipo basado en un corpus controlado (sinopsis de episodios de *Los Simpson*), que permite estudiar de forma sistemática su comportamiento. El objetivo principal es valorar las fortalezas y limitaciones de RAG en un entorno controlado y aportar evidencia sobre su potencial para aplicaciones educativas y multilingües.

## II. ESTADO DEL ARTE

Los grandes modelos de lenguaje (*Large Language Models*, LLM) se han consolidado en los últimos años como una de las herramientas más potentes en el campo de la inteligencia artificial generativa. Su evolución ha estado marcada por una mejora progresiva en la reducción de alucinaciones y en la amplitud del conocimiento representado [1, 18]. No obstante, los LLM presentan limitaciones importantes: entre ellas, el hecho de que su entrenamiento se circunscribe a una fecha de corte, lo que impide acceder de manera nativa a información actualizada. Este aspecto ha impulsado el desarrollo de mecanismos complementarios para enriquecer la capacidad de los modelos con contexto adicional.

Dos enfoques predominan en este ámbito: el *fine-tuning* y *RAG*.

### II-A. Fine-Tuning

El *fine-tuning* (ajuste fino) consiste en reentrenar parcial o totalmente un modelo existente con el fin de adaptarlo a un dominio específico. Existen diversas estrategias: desde el reentrenamiento completo de todas las capas del modelo, hasta aproximaciones más eficientes como *LoRA* (*Low-Rank Adaptation*)[10] tal como se ven en la parte derecha de la Figura 1. Aunque el *fine-tuning* permite especialización y adaptación precisa, comparte limitaciones significativas: la necesidad de grandes volúmenes de datos de calidad y el alto coste computacional del proceso de entrenamiento.

### II-B. Retrieval-Augmented Generation

La arquitectura RAG [13] consiste en enriquecer al modelo con información externa antes de producir una respuesta. En

lugar de modificar los pesos del LLM, se emplea una fuente de datos externa (por ejemplo, bases de datos documentales, APIs o colecciones vectoriales) de la cual se recuperan los fragmentos más relevantes. Estos se integran en el *prompt* del modelo, aportando contexto adicional que mejora la precisión de las respuestas como se aprecia en la parte izquierda de la Figura 1.

Entre las ventajas del RAG destacan:

- La no necesidad de reentrenar el modelo, lo que lo hace más eficiente.
- Una reducción significativa en el grado de alucinaciones, siempre que la fuente de datos sea fiable.
- Su idoneidad para información dinámica o actualizada, como resultados deportivos, vuelos o noticias.

Su principal limitación radica en la dependencia de la calidad del corpus documental, si la base de datos es incompleta o está mal estructurada, la respuesta del sistema puede verse afectada.

### II-C. *Embeddings y bases vectoriales*

Para aprovechar plenamente el RAG, se requiere el uso de *embeddings*, funciones que transforman textos en representaciones numéricas de alta dimensión en un espacio semántico [16, 20]. Esta representación permite que conceptos relacionados —como *Rey* y *Reina*— aparezcan próximos en dicho espacio vectorial, al igual que pares como *hombre* y *mujer*.

Cuando se utiliza una base de datos documental, esta debe ser compatible con operaciones de tipo vectorial. De este modo, es posible indexar documentos y recuperar aquellos más relevantes empleando medidas de similitud como, por ejemplo, el coseno [13, 16, 20].

Finalmente, la evaluación de estos enfoques puede realizarse a partir de métricas cualitativas, por ejemplo, mediante *Gold Tests* que comparan la respuesta generada con una referencia humana, y cuantitativas, centradas en aspectos de rendimiento como latencias o consumo de tokens [9].

### II-D. *Métricas para la evaluación de RAG*

La evaluación de sistemas basados en RAG requiere el uso de métricas diversas que permitan capturar tanto la eficiencia computacional como la calidad y fidelidad de las respuestas generadas. En la literatura, así como en este trabajo, dichas métricas se agrupan en tres categorías principales: cuantitativas, cualitativas y textuales. A continuación, se describen sus fundamentos y las referencias en que se apoyan.

**II-D1. Métricas cuantitativas:** Estas métricas se calculan durante la ejecución del sistema y permiten cuantificar su eficiencia. Habitualmente se incluyen:

- **Latencia total, de recuperación y de generación:** calculadas en milisegundos mediante la función `time_retrieval_and_generation` (líneas 329–364).
- **Tokens procesados:** número de `prompt_tokens`, `completion_tokens` y `total_tokens`, reportados por la función `ollama_generate_with_metrics` (líneas 278–314) [9].

- **Velocidad de generación** (`tokens_per_sec`): cociente entre el número de `completion_tokens` y la duración de la generación.

Estas métricas cuantifican la eficiencia computacional del sistema y permiten comparar configuraciones en términos de coste temporal y uso de recursos. Para este caso de uso, no son tan relevantes, aunque sirven para ofrecer un marco de estabilidad al ejecutarse en local, donde el rendimiento depende de los recursos del usuario (CPU, GPU, RAM, entre otros).

**II-D2. Métricas cualitativas:** La calidad de las respuestas puede evaluarse mediante procedimientos de tipo *Gold Test* [3], en los cuales un LLM evaluador compara la respuesta generada con la referencia y devuelve una puntuación y un *feedback* textual. Este procedimiento consiste en pedir a un LLM evaluador que compare la respuesta generada con la referencia y devuelva:

- **Gold score** (0–10) y *feedback* textual en formato JSON [3].

**II-D3. Métricas de groundedness y retrieval support:** Diversos trabajos recientes han introducido métricas de *groundedness* y *retrieval support* [8, 21], cuyo objetivo es medir hasta qué punto las respuestas generadas se apoyan realmente en la evidencia recuperada.

**II-D3a. Groundedness:** Se calcula en la fase de evaluación y refleja el grado en que la respuesta producida por el LLM está anclada en el contexto documental recuperado. Existen dos modalidades de cálculo:

- **Modo semántico:** Convierte tanto la respuesta generada como los fragmentos recuperados en *embeddings*, y posteriormente calcula la similitud del coseno entre ellos. Un valor alto indica que la respuesta está bien fundamentada en el contenido semántico del corpus.
- **Modo léxico:** Evalúa el solapamiento de *n-gramas* (uni-gramas y bigramas) entre respuesta y contexto, tras un proceso de normalización y eliminación de *stopwords*.

En ambos casos, el valor obtenido se normaliza en el rango [0,1] y también se reporta en una escala alternativa de 0 a 10 bajo el nombre `factual_consistency_0_10`. En la literatura también se presenta la alucinación como antítesis del *groundedness*, siendo complementarias.

**II-D3b. Retrieval Support (gold):** Esta métrica utiliza el mismo procedimiento de cálculo pero aplicado a la respuesta de referencia (*gold*) en lugar de la respuesta generada. De esta forma, mide hasta qué punto la respuesta correcta estaba contenida en los fragmentos recuperados.

Esta métrica resulta especialmente útil porque permite diferenciar entre dos tipos de errores:

- **Fallos de recuperación:** cuando el sistema no accedió al contexto necesario.
- **Fallos de generación:** cuando el LLM no aprovechó adecuadamente el contexto que sí estaba disponible.

Estas aproximaciones están en línea con propuestas recientes de la literatura sobre métricas de *faithfulness* y *groundedness* en sistemas RAG, que buscan garantizar la fidelidad de las respuestas a la evidencia proporcionada [8, 21].




Figura 1. Comparativa conceptual entre RAG y Fine-Tuning. Fuente: [7].

**II-D4. Métricas textuales:** Finalmente, se emplean métricas textuales clásicas en la evaluación de NLP, ampliamente utilizadas en tareas como lectura automática y resumen:

- **Exact Match (EM):** indica si la respuesta generada coincide exactamente con la de referencia, tras normalización.
- **F1 por tokens:** balance entre precisión y exhaustividad en el solapamiento de tokens[19].
- **ROUGE-L:** medida de similitud basada en la subsecuencia común más larga[14].
- **Levenshtein similarity:** grado de similitud según la distancia de edición[12].

Además, es habitual complementar estas métricas con *acuracias* suaves mediante umbrales (por ejemplo, ROUGE-L  $\geq 0,7$ ; Levenshtein  $\geq 0,8$ ) y con estimaciones de intervalos de confianza mediante técnicas de *bootstrap* [6]. No obstante, trabajos recientes han señalado la necesidad de revisar críticamente la validez de estas métricas clásicas [11].

### III. METODOLOGÍA

La metodología adoptada en este trabajo se diseñó con el objetivo de analizar de manera sistemática el funcionamiento de un sistema basado en RAG y extraer conclusiones sobre sus fortalezas y limitaciones en distintos escenarios. El proceso se organizó en cinco fases principales: construcción del corpus, implementación del sistema, diseño experimental, evaluación y análisis de resultados.

#### III-A. Fase 1: Construcción del corpus

Se elaboró un banco de pruebas controlado a partir de las sinopsis de la primera temporada de *Los Simpson*, traducidas a

tres idiomas (catalán, español e inglés). El corpus se compone de 13 archivos en formato `.txt`, cada uno correspondiente a un episodio. Todos los archivos siguen una estructura homogénea con campos de título, temporada, episodio, sinopsis y personajes destacados, lo que facilita la indexación posterior en la base de datos vectorial [20]. Un ejemplo de registro es el siguiente:

- **Título:** Simpsons Roasting on an Open Fire
- **Temporada:** 1
- **Episodio:** 1
- **Sinopsis:** En Navidad, Homer descubre que no recibirá bono navideño y toma un trabajo como Santa Claus. La familia adopta a *Santa's Little Helper*.
- **Personajes destacados:** Homer, Bart, Marge, Santa's Little Helper

#### III-B. Fase 2: Implementación del sistema RAG

La implementación del prototipo se realizó en entorno local, combinando diferentes componentes para ejecutar y evaluar consultas.

**III-B1. Ollama:** Se ha empleado **Ollama**[17], un servidor local que permite descargar, gestionar y ejecutar modelos de lenguaje de código abierto. Esta elección ofrece independencia frente a servicios en la nube, lo que aporta mayor control y reproducibilidad de los experimentos. Además de modelos de lenguaje (LLM), Ollama proporciona modelos de *embeddings*, fundamentales para la construcción del índice vectorial sobre el que se sustenta la arquitectura RAG, siguiendo el enfoque propuesto por Lewis et al. [13].

**III-B2. Python y librerías asociadas:** El desarrollo del sistema se llevó a cabo íntegramente en *Python*, dentro de un entorno virtual que garantiza el control del versionado de librerías y la reproducibilidad. Entre las principales dependencias destacan:

- **ChromaDB**[4]: gestión de bases de datos vectoriales, permitiendo almacenar documentos junto con sus *embeddings* y habilitando búsquedas semánticas mediante similitud del coseno.
- **LlamaIndex** [15]: *framework* que orquesta la interacción entre LLM y fuentes externas, facilitando la construcción del flujo RAG y la configuración de parámetros experimentales.
- **Pandas**: manipulación y análisis de datos en *DataFrames*, permitiendo aplicar estadísticas descriptivas y comparativas.
- **Requests**: para realizar llamadas HTTP a la API de Ollama, necesarias en la gestión de modelos y la ejecución de inferencias.

En conjunto, estos componentes proporcionan un flujo reproducible y extensible para la construcción de un prototipo RAG en entorno local.

### III-C. Fase 3: Diseño experimental

El diseño experimental se estructuró como un barrido sistemático de combinaciones entre tres modelos de lenguaje: Llama3, Mistral, DeepSeek-R1; tres modelos de *embeddings*: *nomic-embed-text*, *all-minilm*, *mxbai-embed-large*; y tres idiomas: catalán, español, inglés. El parámetro *top-k* se fijó en 3, correspondiente al número de documentos recuperados en cada consulta. Con la cantidad de 10 preguntas en el *Gold Test* (ver Cuadro I), se obtuvieron 270 ejecuciones en total.

Para implementar estas pruebas se desarrollaron tres *scripts* en Python[2]:

- `benchmark_rag_tokenized.py`: ejecuta las consultas, captura las respuestas generadas, mide latencias y uso de tokens, e incorpora la evaluación cualitativa mediante *Gold Test*, *groundedness* y *retrieval support*.
- `aggregate_bench_outputs.py`: integra los resultados parciales en un único archivo consolidado para su análisis posterior, añadiendo metadatos relevantes.
- `analyze_schema_bench.py`: aplica métricas textuales (EM, F1, ROUGE-L, Levenshtein) y genera estadísticas agregadas e intervalos de confianza mediante *bootstrap*.

El siguiente fragmento de `benchmark_rag_tokenized.py` muestra cómo se ejecuta una consulta y se registran métricas de latencia y conteo de tokens:

### III-D. Fase 4: Evaluación

Las respuestas obtenidas se midieron mediante las métricas descritas en el Estado del Arte. En este trabajo se aplicaron de la siguiente manera:

- **Cuantitativas**: latencias de recuperación y generación, tokens procesados, capturados automáticamente durante la ejecución de los *scripts*.
- **Cualitativas**: puntuación de *Gold Test*, *groundedness* y *retrieval support*, evaluadas mediante un LLM encargado de contrastar las respuestas con la referencia [3, 21].
- **Textuales**: Exact Match, F1, ROUGE-L y Levenshtein, calculados a posteriori con el `analyze_schema_bench.py` [12, 14, 19].

### III-E. Fase 5: Análisis y discusión

Finalmente, los resultados se consolidaron y organizaron en tablas comparativas, lo que permitió extraer patrones por pregunta, idioma, *embedding* y modelo. Este análisis constituye la base de la discusión posterior.

### III-F. Consideraciones metodológicas

El diseño metodológico se apoyó en dos principios: reproducibilidad y alineación con la literatura. La reproducibilidad se garantizó mediante la construcción de un corpus homogéneo y la automatización completa del pipeline experimental en *scripts* de Python. La alineación con la literatura se aseguró siguiendo la arquitectura RAG descrita por Lewis et al. [13] y aplicando métricas recomendadas en evaluaciones recientes de LLMs [9].

Se incorporaron además criterios de robustez estadística, como el uso de *bootstrapping* para estimar intervalos de confianza y la adopción de *soft accuracies*, lo que reduce la dependencia de casos aislados [6].

Finalmente, conviene señalar limitaciones inherentes al planteamiento: el corpus empleado es reducido y prototípico, por lo que los resultados no son directamente extrapolables a contextos educativos más amplios. Aun así, el enfoque seguido proporciona un marco controlado que permite analizar con precisión el comportamiento de un sistema RAG bajo distintas configuraciones.

## IV. RESULTADOS

La extracción de resultados presenta la siguiente forma; se han reducido los campos mostrados para ubicar al lector (ver Cuadro VII). El dataset completo consta de 270 ejecuciones, cada una de ellas asociada a una combinación de parámetros de LLM, *embedding*, idioma y pregunta.

A partir de estos registros, el análisis se ha realizado mediante la agregación de resultados y el cálculo de medias aritméticas de las métricas, de acuerdo con la dimensión de estudio (por pregunta, por idioma, por *embedding* o por modelo). Este enfoque permite comparar de manera sistemática el comportamiento del sistema en distintos escenarios, evitando que casos aislados distorsionen la interpretación global.

Para la identificación de mejores y peores casos en las preguntas del *Gold Test*, se ha seguido un criterio combinado: se priorizaron métricas textuales de similitud (*ROUGE-L*, F1) junto con la valoración cualitativa del *Gold Score*. De esta forma, una pregunta se consideró **mejor caso** cuando presentaba simultáneamente altos valores de ROUGE/F1 y una

Cuadro I  
GOLD TEST EN CASTELLANO

| Índice | Pregunta                                                                       | Respuesta                                              |
|--------|--------------------------------------------------------------------------------|--------------------------------------------------------|
| 1      | ¿Quién es el ídolo de Lisa?                                                    | Bleeding Gums Murphy                                   |
| 2      | ¿Qué instrumento toca Lisa?                                                    | Saxofón                                                |
| 3      | ¿Cómo se llama el perro de Bart?                                               | Santa's Little Helper                                  |
| 4      | ¿En qué trabaja Homer Simpson?                                                 | Inspector de seguridad en la planta nuclear            |
| 5      | ¿En qué episodio Homer es confundido con Big Foot?                             | The Call of the Simpsons (S01E07)                      |
| 6      | ¿Qué hace Bart para impresionar a los chicos populares en "The Telltale Head"? | Cortar la cabeza de la estatua de Jebediah Springfield |
| 7      | ¿Quién ayuda a Bart a enfrentarse a Nelson en "Bart the General"?              | El abuelo Abe y Herman                                 |
| 8      | ¿Qué trabajo extra toma Homer en Navidad en el episodio piloto?                | Santa Claus en un centro comercial                     |
| 9      | ¿Qué fotografía comprometedoras toma Bart en "Homer's Night Out"?              | Una foto de Homer bailando con una bailarina           |
| 10     | ¿Quién realmente comete el robo en "Krusty Gets Busted"?                       | Sideshow Bob                                           |

puntuación de *Gold Score* elevada, mientras que se consideró **peor caso** cuando todas estas métricas se situaban en valores mínimos. En los apartados siguientes se muestran las métricas esenciales que soportan estos argumentos, ilustrando cómo la combinación de indicadores cuantitativos y cualitativos permite discriminar con claridad entre respuestas exitosas y fallidas.

El análisis se organiza en distintos niveles con el fin de evaluar de manera progresiva el rendimiento del sistema. En primer lugar, se presentan ejemplos individuales de preguntas del *Gold Test*, con el objetivo de ilustrar cómo se registran las métricas y qué diferencias existen entre casos de éxito y de fracaso. A continuación, los resultados se agregan en tres dimensiones de estudio: por idioma, por modelo de *embedding* y por modelo de lenguaje. Finalmente, se sintetiza la mejor configuración encontrada para cada idioma en un *leaderboard*, que servirá de referencia para la discusión crítica posterior.

#### IV-A. Ejemplo de registros individuales

El Cuadro VII muestra un extracto de cinco registros, reduciendo el número de campos para facilitar la comprensión. Cada fila corresponde a la respuesta generada por una combinación de *LLM*, *embedding* e idioma, en relación con una pregunta del *Gold Test*. Este ejemplo permite visualizar cómo se estructuran los datos y qué métricas se registran en cada ejecución.

#### IV-B. Mejor y peor caso por pregunta

El Cuadro II muestra los promedios de las métricas por cada pregunta, de esta manera podemos identificar posibles sesgos ya sea en la recuperación de información como en la construcción del corpus.

#### IV-C. Resultados agregados por idioma

El Cuadro III presenta los promedios de métricas obtenidos para cada idioma. Esto permite observar patrones asociados a la naturaleza multilingüe de los embeddings y valorar posibles sesgos en la calidad de las respuestas según la lengua.

#### IV-D. Resultados agregados por embedding

El Cuadro IV recoge la comparación entre los tres modelos de embeddings empleados. El análisis se centra en el compromiso entre precisión textual, groundedness y eficiencia (latencia).

#### IV-E. Resultados agregados por modelo

El Cuadro V compara los tres LLM utilizados. Este análisis permite observar tanto la calidad de las respuestas como las diferencias en latencia, lo que resulta clave para valorar la aplicabilidad práctica de cada modelo.

#### IV-F. Leaderboard por idioma

Finalmente, el Cuadro VI sintetiza la mejor configuración obtenida en cada idioma, combinando modelo, embedding y métricas asociadas. Este resumen servirá como punto de partida para la discusión crítica de los resultados.

## V. DISCUSIÓN

En este apartado se analizan e interpretan los resultados experimentales obtenidos, con el fin de identificar patrones, fortalezas y limitaciones en el comportamiento del sistema. La discusión se organiza en dos niveles: en primer lugar, se examinan casos concretos de preguntas del *Gold Test* que representan los mejores y peores escenarios de rendimiento; en segundo lugar, se comparan los resultados a nivel agregado por idioma, por *embedding* y por modelo, lo que permite extraer conclusiones más generales. Por último, se presenta una síntesis de las mejores configuraciones por idioma.

Para contextualizar el análisis, el Cuadro I recoge el conjunto de preguntas utilizadas en el *Gold Test* de esta memoria. Cada pregunta se asocia a un índice que será utilizado a lo largo de la discusión para referirse a los distintos casos evaluados.

#### V-A. Análisis por pregunta

Atendiendo las estadísticas por pregunta (ver Cuadro II), la **pregunta 6**, mostrada en el Cuadro I, constituye el mejor escenario observado, con un ROUGE-L medio de 0.72 (IC95 = [0.65; 0.79]), un F1 medio de 0.73 y una puntuación media de *Gold Test* de 9.13/10. Estos valores se acompañan de un *groundedness* de 0.87 y un *retrieval support* de 0.83, lo que refleja que tanto la recuperación como la generación se apoyaron de manera sólida en el contexto disponible. La baja tasa de alucinación 0.13 confirma que la respuesta se mantuvo fiel al corpus. Este comportamiento sugiere que la pregunta estaba bien representada en los documentos y no presentaba ambigüedad, permitiendo al sistema ofrecer una respuesta precisa y coherente.

En contraste, la **pregunta 3**, mostrada en el Cuadro I, representa el escenario opuesto. Obtuvo un ROUGE-L medio de apenas 0.03 (IC95 = [0.01; 0.05]), un F1 equivalente y una puntuación de *Gold Test* de 0.76/10 aparte de la tasa de alucinación más alta de 0.22. Resulta llamativo que, pese a estos valores, el *groundedness* de 0.78 y el *retrieval support* de 0.69 fueran relativamente altos. Esto indica que el sistema sí accedió a fragmentos del corpus vinculados a la consulta, pero la fase de generación no logró producir una respuesta alineada con la referencia. La discrepancia puede deberse a varios factores: ambigüedad en la formulación de la pregunta, incompletitud del corpus o una deficiencia en el alineamiento entre recuperación y generación.

Este contraste evidencia un patrón general de los experimentos: cuando la información relevante está claramente representada en el corpus y la pregunta es poco ambigua, el sistema ofrece respuestas fieles y precisas. En cambio, en escenarios de mayor ambigüedad o con documentación incompleta, el rendimiento se degrada de forma notable, incluso cuando la recuperación inicial es adecuada. Estas observaciones constituyen un primer indicio de la importancia de la calidad y cobertura del corpus en la fiabilidad de los sistemas basados en RAG.

#### V-B. Análisis por idioma

Más allá de casos concretos, resulta de interés analizar cómo varía el rendimiento en función del idioma (ver Cuadro III). Los resultados muestran diferencias relevantes entre lenguas. El **español** presenta las mejores métricas textuales, con un ROUGE-L medio de 0.37 (IC95 = [0.31; 0.43]) y un F1 medio de 0.38, lo que refleja un mayor alineamiento entre las respuestas generadas y las de referencia. Este comportamiento se acompaña de un *grounding* medio de 0.84. No obstante, el *Gold Score* medio es relativamente bajo de 4.97/10, lo que sugiere que, pese a la similitud léxica, el evaluador LLM consideró las respuestas de menor calidad semántica o menos precisas respecto a la referencia.

En contraste, el **catalán** obtiene el peor desempeño en términos de ROUGE-L (0.32; IC95 = [0.26; 0.38]) y F1 de 0.33, con un *grounding* de 0.83. Sin embargo, el *Gold Score* de 5.54/10 supera al del español, lo que indica que, aunque las respuestas presentan menos coincidencias textuales, fueron percibidas como razonablemente válidas por el evaluador. Este fenómeno puede explicarse por la naturaleza multilingüe de los *embeddings* empleados, que tienden a favorecer idiomas mayoritarios como el inglés o el español [5]. Además, el catalán presenta la mayor latencia promedio de 24.6 segundos, lo que podría asociarse a un menor grado de optimización de los modelos en esta lengua.

Por su parte, el **inglés** muestra un equilibrio más favorable: alcanzó un F1 medio de 0.38 (IC95 = [0.34; 0.42]) y un ROUGE-L de 0.35 (IC95 = [0.31; 0.39]), cifras comparables a las del español, pero con un *Gold Score* claramente superior de 6.64/10. Asimismo, obtuvo mayor *groundedness* con 0.85, lo que sugiere que en este idioma los modelos lograron respuestas mejor fundamentadas en el contexto, probablemente debido a que el inglés es la lengua dominante en el entrenamiento de la mayoría de LLM actuales.

En conjunto, estos resultados reflejan una tensión entre las métricas automáticas de similitud léxica y la valoración cualitativa de las respuestas: mientras que el español destaca en coincidencia textual, el catalán obtiene una mejor percepción subjetiva, y el inglés se posiciona como el idioma más equilibrado al combinar alta similitud con un mayor *Gold Score*. Ello evidencia la necesidad de considerar métricas complementarias y de prestar atención a las limitaciones de los *embeddings* multilingües en lenguas con menor representación en los datos de entrenamiento.

#### V-C. Análisis por embedding

En cuanto al impacto de los *embeddings*, los resultados evidencian diferencias significativas en términos de precisión textual y eficiencia (ver Cuadro IV). El modelo *nomic-embed-text* obtiene el mejor rendimiento global, alcanzando un ROUGE-L medio de 0.38 (IC95 = [0.33; 0.43]) y un F1 medio de 0.40. Asimismo, su *groundedness* medio es de 0.87, lo que indica que las respuestas generadas se apoyaron de forma consistente en el contexto recuperado. Estos valores se acompañan de una baja tasa de alucinación de 0.13 y de una latencia media moderada de 21.7 segundos, lo que lo convierte en el *embedding* más equilibrado de los evaluados.

Por el contrario, *mxbai-embed-large* presenta un ROUGE-L inferior (0.33; IC95 = [0.28; 0.38]) y un F1 medio de 0.35. Aunque mantiene un *groundedness* prácticamente idéntico de 0.87 y una tasa de alucinación equivalente a 0.13, su latencia es sensiblemente mayor con 25.6 segundos. Esta diferencia sugiere que, si bien ambos *embeddings* permiten generar respuestas basadas en el contexto, *nomic-embed-text* ofrece un mejor compromiso entre fidelidad textual y eficiencia computacional.

En una posición intermedia se encuentra *all-minilm*, con un ROUGE-L medio de 0.33 (IC95 = [0.27; 0.39]) y un F1 de 0.34. Aunque sus valores de *groundedness* es de 0.79 y *retrieval support* de 0.70 resultan algo inferiores, destaca por ser el *embedding* con la menor latencia promedio con 21.1 segundos. Esto lo convierte en una opción competitiva cuando la eficiencia temporal es prioritaria, aun a costa de una ligera pérdida en precisión textual.

En conjunto, estos resultados muestran cómo la elección del *embedding* afecta de manera directa al equilibrio entre fidelidad semántica y eficiencia computacional. Mientras *nomic-embed-text* se posiciona como la opción más robusta, *all-minilm* puede ser preferible en escenarios con restricciones de tiempo de respuesta, y *mxbai-embed-large* no logra traducir su mayor complejidad en beneficios proporcionales, penalizando en latencia. Estas observaciones concuerdan con trabajos previos sobre el comportamiento de *embeddings* multilingües y de distinta dimensionalidad [20].

#### V-D. Análisis por modelo

El análisis comparativo de modelos revela diferencias notables en rendimiento y eficiencia (ver Cuadro V). El modelo **Llama3** presenta los mejores resultados en métricas textuales, con un ROUGE-L medio de 0.43 (IC95 = [0.37; 0.49]) y un



Cuadro II  
RESULTADOS AGREGADOS POR PREGUNTA DEL *Gold Test* (MEDIAS E IC95).

| Pregunta | n  | EM          | F1                      | ROUGE-L                 | LEV-SIM     | Gold Score  | Halluc.     | Grounded.   | Retr. Support | Latencia total (s) |
|----------|----|-------------|-------------------------|-------------------------|-------------|-------------|-------------|-------------|---------------|--------------------|
| 1        | 27 | <b>0.37</b> | 0.56 [0.41–0.70]        | 0.56 [0.41–0.70]        | <b>0.57</b> | 5.78        | 0.19        | 0.81        | 0.77          | 26.28              |
| 2        | 27 | 0.00        | 0.18 [0.10–0.26]        | 0.18 [0.10–0.26]        | 0.26        | 8.21        | 0.18        | 0.82        | 0.70          | 25.32              |
| 3        | 27 | 0.00        | 0.03 [0.01–0.05]        | 0.03 [0.01–0.05]        | 0.18        | 0.76        | <b>0.22</b> | 0.78        | 0.69          | 21.98              |
| 4        | 27 | 0.00        | 0.30 [0.23–0.36]        | 0.23 [0.18–0.30]        | 0.28        | 4.28        | 0.17        | 0.83        | 0.72          | 21.90              |
| 5        | 27 | 0.00        | 0.38 [0.29–0.47]        | 0.38 [0.29–0.47]        | 0.30        | 7.25        | 0.12        | <b>0.88</b> | <b>0.85</b>   | 20.61              |
| 6        | 27 | 0.00        | <b>0.73</b> [0.66–0.79] | <b>0.72</b> [0.65–0.79] | <b>0.73</b> | <b>9.13</b> | 0.13        | 0.87        | 0.83          | 22.05              |
| 7        | 27 | 0.00        | 0.44 [0.40–0.47]        | 0.44 [0.40–0.47]        | 0.28        | 7.76        | 0.13        | 0.87        | 0.78          | 21.11              |
| 8        | 27 | 0.00        | 0.35 [0.28–0.41]        | 0.26 [0.21–0.32]        | 0.28        | 5.44        | 0.16        | 0.84        | 0.74          | 22.26              |
| 9        | 27 | 0.00        | 0.36 [0.29–0.43]        | 0.35 [0.29–0.42]        | 0.32        | 2.79        | 0.13        | 0.87        | 0.83          | <b>26.53</b>       |
| 10       | 27 | 0.00        | 0.31 [0.26–0.36]        | 0.31 [0.26–0.36]        | 0.19        | 5.74        | 0.15        | 0.85        | 0.76          | 20.21              |

Cuadro III  
RESULTADOS AGREGADOS POR IDIOMA (MEDIAS E IC95).

| Idioma       | n  | EM          | F1                      | ROUGE-L                 | LEV-SIM     | Gold Score  | Halluc.     | Grounded.   | Retr. Support | Latencia total (s) |
|--------------|----|-------------|-------------------------|-------------------------|-------------|-------------|-------------|-------------|---------------|--------------------|
| Catalán (ca) | 90 | 0.03        | 0.33 [0.27–0.39]        | 0.32 [0.26–0.38]        | 0.34        | 5.54        | <b>0.17</b> | 0.83        | 0.77          | <b>24.63</b>       |
| Inglés (en)  | 90 | 0.02        | <b>0.38</b> [0.34–0.42] | 0.35 [0.31–0.39]        | 0.31        | <b>6.64</b> | 0.15        | <b>0.85</b> | 0.76          | 22.36              |
| Español (es) | 90 | <b>0.06</b> | <b>0.38</b> [0.32–0.44] | <b>0.37</b> [0.31–0.43] | <b>0.37</b> | 4.97        | 0.16        | 0.84        | <b>0.77</b>   | 21.48              |

Cuadro IV  
RESULTADOS AGREGADOS POR *embedding* (MEDIAS E IC95).

| Embedding         | n  | EM          | F1                      | ROUGE-L                 | LEV-SIM     | Gold Score  | Halluc.     | Grounded.   | Retr. Support | Latencia total (s) |
|-------------------|----|-------------|-------------------------|-------------------------|-------------|-------------|-------------|-------------|---------------|--------------------|
| all-minilm        | 90 | <b>0.04</b> | 0.34 [0.28–0.40]        | 0.33 [0.27–0.39]        | 0.33        | 5.48        | <b>0.21</b> | 0.79        | 0.70          | <b>21.13</b>       |
| mxbai-embed-large | 90 | 0.02        | 0.35 [0.29–0.40]        | 0.33 [0.28–0.38]        | 0.32        | 5.70        | 0.13        | <b>0.87</b> | <b>0.80</b>   | 25.61              |
| nomic-embed-text  | 90 | <b>0.04</b> | <b>0.40</b> [0.34–0.45] | <b>0.38</b> [0.33–0.43] | <b>0.36</b> | <b>5.96</b> | 0.13        | <b>0.87</b> | <b>0.80</b>   | 21.74              |

F1 medio de 0.45. Aunque su *Gold Score* medio se mantiene en un nivel moderado con 5.87/10, destaca por su baja latencia total de 11.2 segundos, muy inferior a la de los otros modelos, lo que lo convierte en la opción más eficiente. Su *groundedness* medio es de 0.83, lo que indica un grado sólido de apoyo en el contexto recuperado, con una tasa de alucinación relativamente superior de 0.17 respecto a otros modelos.

En contraste, **DeepSeek-R1** obtiene los peores resultados en ROUGE-L (0.28; IC95 = [0.23; 0.33]) y F1 de 0.29, con un *Gold Score* medio ligeramente inferior de 5.41/10. No obstante, su *groundedness* medio de 0.85 es comparable al de los demás modelos, lo que refleja que las respuestas siguen estando razonablemente ancladas en el contexto. Su principal limitación radica en la eficiencia: alcanza la mayor latencia total de 43.6 segundos, más de cuatro veces superior a la de Llama3 debido a la fase de razonamiento, lo que compromete su aplicabilidad práctica en entornos de uso interactivo.

El modelo **Mistral** se sitúa en una posición intermedia, con un ROUGE-L de 0.33 (IC95 = [0.28; 0.38]) y un F1 de 0.35, así como un *Gold Score* de 5.86/10. Su *groundedness* de 0.85 y tasa de alucinación 0.15 son comparables a los de DeepSeek-R1, con latencias relativamente bajas de 13.7 segundos, lo que lo hace más equilibrado en términos de fiabilidad y eficiencia.

En conjunto, los resultados ponen de manifiesto un patrón claro: Llama3 ofrece el mejor equilibrio entre precisión y velocidad, Mistral se presenta como una alternativa razonable con un compromiso aceptable, y DeepSeek-R1 resulta poco adecuado para aplicaciones prácticas debido a su elevada latencia. Esta comparación subraya la necesidad de valorar no solo la calidad de las respuestas, sino también la eficiencia computacional como criterio en la selección de modelos.

#### V-E. Síntesis por idioma

Finalmente, la extracción de la mejor configuración de parámetros por idioma refuerza la robustez del modelo Llama3 (ver Tabla VI). En **catalán**, la combinación con *nomic-embed-text* alcanza un ROUGE-L medio de 0.48 y un F1 de 0.48, acompañado de un *Gold Score* de 5.30/10. Si bien estos valores son moderados en comparación con los otros idiomas, destaca por presentar la tasa de alucinación más baja con 0.16, lo que indica un mejor control en la fidelidad de las respuestas.

En **inglés**, la configuración más eficiente corresponde a Llama3 junto con *all-minilm*, con un ROUGE-L de 0.47 y el mayor F1 del conjunto con 0.49. Además, alcanza el mejor *Gold Score* de 6.64/10 y la menor latencia total de 5.99 segundos, lo que lo convierte en la opción más equilibrada en términos de calidad y eficiencia.

En **español**, nuevamente la mejor combinación se obtiene con Llama3 y *nomic-embed-text*, alcanzando un ROUGE-L de 0.46 y un F1 de 0.48. Su principal fortaleza es el mayor grado de *groundedness* de 0.85, lo que indica que las respuestas en este idioma se apoyaron de manera más consistente en la evidencia recuperada, aunque con una latencia mayor de 14.1 segundos.

En conjunto, estos resultados muestran que Llama3 se consolida como el modelo más robusto en todos los idiomas, pero la elección del *embedding* óptimo depende de la lengua: *all-minilm* resulta más eficiente en inglés, mientras que *nomic-embed-text* ofrece un mejor equilibrio en las lenguas romances. Este comportamiento es coherente con estudios previos sobre sesgo hacia lenguas mayoritarias en modelos multilingües [5, 20].

Cuadro V  
RESULTADOS AGREGADOS POR MODELO LLM (MEDIAS E IC95).

| Modelo      | n  | EM          | F1                      | ROUGE-L                 | LEV-SIM     | Gold Score  | Halluc.     | Grounded.   | Retr. Support | Latencia total (s) |
|-------------|----|-------------|-------------------------|-------------------------|-------------|-------------|-------------|-------------|---------------|--------------------|
| DeepSeek-R1 | 90 | 0.01        | 0.29 [0.24–0.34]        | 0.28 [0.23–0.33]        | 0.27        | 5.41        | 0.15        | <b>0.85</b> | <b>0.77</b>   | 43.61              |
| Llama3      | 90 | <b>0.07</b> | <b>0.45</b> [0.39–0.51] | <b>0.43</b> [0.37–0.49] | <b>0.42</b> | <b>5.87</b> | <b>0.17</b> | 0.83        | <b>0.77</b>   | <b>11.21</b>       |
| Mistral     | 90 | 0.03        | 0.35 [0.30–0.40]        | 0.33 [0.28–0.38]        | 0.33        | 5.86        | 0.15        | <b>0.85</b> | <b>0.77</b>   | 13.65              |

Cuadro VI  
LEADERBOARD: MEJOR CONFIGURACIÓN POR IDIOMA (MEDIAS E IC95).

| Idioma       | Modelo | Embedding        | n  | EM   | F1                      | ROUGE-L                 | LEV-SIM     | Gold Score  | Halluc.     | Grounded.   | Latencia total (s) |
|--------------|--------|------------------|----|------|-------------------------|-------------------------|-------------|-------------|-------------|-------------|--------------------|
| Catalán (ca) | Llama3 | nomic-embed-text | 10 | 0.10 | 0.48 [0.26–0.68]        | <b>0.48</b> [0.26–0.68] | <b>0.47</b> | 5.30        | 0.16        | 0.84        | 13.48              |
| Inglés (en)  | Llama3 | all-minilm       | 10 | 0.10 | <b>0.49</b> [0.34–0.66] | 0.47 [0.31–0.65]        | 0.43        | <b>6.64</b> | <b>0.18</b> | 0.82        | <b>5.99</b>        |
| Español (es) | Llama3 | nomic-embed-text | 10 | 0.10 | 0.48 [0.27–0.68]        | 0.46 [0.26–0.67]        | 0.46        | 6.02        | 0.15        | <b>0.85</b> | 14.13              |

## VI. CONCLUSIONES

El presente Trabajo de Fin de Máster ha demostrado la viabilidad de implementar un sistema de RAG utilizando modelos locales de lenguaje gestionados mediante Ollama, junto con *embeddings* vectoriales y bases de datos semánticas. A partir de un corpus prototípico se han evaluado diferentes configuraciones de LLM, *embeddings* e idiomas, lo que ha permitido analizar de forma sistemática las ventajas y limitaciones de este enfoque en un entorno controlado.

En términos generales, los resultados mostraron un bajo grado de alucinación y un nivel elevado de fiabilidad en las respuestas. La métrica de *groundedness* evidenció que las respuestas generadas se apoyaron de forma consistente en el contexto recuperado, mientras que los *Gold Tests* y las métricas textuales reflejaron variaciones relevantes en función de la configuración seleccionada.

Entre los principales hallazgos destacan:

- **Modelos (LLM):** Llama3 se consolidó como la opción más equilibrada, con mejores resultados en métricas textuales y una latencia significativamente inferior a alternativas como DeepSeek-R1, lo que lo hace más adecuado para entornos de uso interactivo.
- **Embeddings:** `nomic-embed-text` ofreció un rendimiento más robusto, especialmente en español y catalán, mientras que `mxbai-embed-large` no tradujo su mayor complejidad en mejoras claras y penalizó en latencia.
- **Idiomas:** el español mostró mejores métricas automáticas, mientras que el catalán obtuvo valoraciones cualitativas relativamente más favorables, reflejando posibles sesgos de los *embeddings* hacia lenguas mayoritarias.
- **Leaderboard:** en todos los idiomas, la mejor configuración incluyó Llama3, con variaciones en el *embedding* óptimo: `all-minilm` en inglés y `nomic-embed-text` en lenguas romances.

No obstante, el estudio también ha puesto de relieve ciertas limitaciones: la dependencia de un corpus reducido y prototípico, la posible ambigüedad en algunas preguntas del *Gold Test* y la sensibilidad de los resultados a la cobertura documental.

De cara a trabajos futuros, se identifican varias líneas de mejora directamente vinculadas a estas limitaciones:

- Ampliar el análisis a corpus educativos reales, que permitan validar el potencial de RAG en la generación y corrección de exámenes.

- Diseñar y validar *Gold Tests* más completos, que reduzcan la ambigüedad de las preguntas y reflejen mejor la complejidad del dominio.
- Incorporar métricas avanzadas de fidelidad (*faithfulness*) [9, 11] y complementar la evaluación automática con juicios humanos sistemáticos.

## REFERENCIAS

- [1] Anthropic. Constitutional ai: Harmlessness from ai feedback. *arXiv preprint arXiv:2212.08073*, 2023.
- [2] R. S.-P. Besga. Repositorio del tfm. <https://github.com/RamonSPB/LLM-Agents-TFM>, 2025. Acceso en modo lectura.
- [3] C.-H. Chiang et al. Can llms evaluate llms? *arXiv preprint arXiv:2306.05685*, 2023.
- [4] Chroma. Chroma: The ai-native open-source embedding database. <https://www.trychroma.com>, 2025. Accedido: 2025-09-10.
- [5] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov. Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8440–8451, 2020.
- [6] B. Efron and R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1994.
- [7] J. Fleszar. Improving llm performance: The various ways to fine-tune your llms, 2023. Accedido: 2025-09-10.
- [8] T. Gao et al. Rethinking with retrieval: Faithful large language model inference. *arXiv preprint arXiv:2301.00303*, 2023.
- [9] P. Henderson et al. Towards practical evaluation of large language models. *arXiv preprint arXiv:2307.03109*, 2023.
- [10] E. J. Hu et al. Lora: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021.
- [11] P. Laban et al. Summeval: Re-evaluating summarization evaluation. *Transactions of the Association for Computational Linguistics*, 10:163–177, 2022.
- [12] V. I. Levenshtein. Binary codes capable of correcting deletions, insertions, and reversals. *Soviet Physics Doklady*, 10(8):707–710, 1966.
- [13] P. Lewis et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [14] C.-Y. Lin. Rouge: A package for automatic evaluation of summaries. In *Proceedings of the ACL Workshop on Text Summarization Branches Out*, 2004.
- [15] LlamaIndex. Llamaindex: Data framework for llm applications. <https://www.llamaindex.ai>, 2025. Accedido: 2025-09-10.
- [16] T. Mikolov, K. Chen, G. Corrado, and J. Dean. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013.
- [17] Ollama. Ollama: Run llms locally. <https://ollama.ai>, 2025. Accedido: 2025-09-10.
- [18] OpenAI. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- [19] P. Rajpurkar et al. Squad: 100,000+ questions for machine comprehension of text. In *Proceedings of EMNLP*, 2016.
- [20] N. Reimers and I. Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of EMNLP-IJCNLP*, 2019.
- [21] K. Shuster et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. *arXiv preprint arXiv:2005.11401*, 2021.

[22] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. van den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016.

Cuadro VII  
EXTRACTO DE RESULTADOS CON MÉTRICAS ASOCIADAS (5 REGISTROS).

| ID | Pregunta                                         | Gold Answer                                 | Predicted Answer                                                                               | Idioma | LLM         | Emb.       | Tipek | Lat. Pol. (s) | Lat. Rec. (s) | Lat. Gen. (s) | Prompt Ticks | Compl. Ticks | Tot. Ticks | Ticks | Gold Score | Feedback                                                                                     | Haluc. | Grounded. | Ret. Supp. | EM | F1    | ROUGE-L | Les. Sim. |
|----|--------------------------------------------------|---------------------------------------------|------------------------------------------------------------------------------------------------|--------|-------------|------------|-------|---------------|---------------|---------------|--------------|--------------|------------|-------|------------|----------------------------------------------------------------------------------------------|--------|-----------|------------|----|-------|---------|-----------|
| 1  | Qui és l'home de la capa?                        | Bleeding Gums Murphy                        | No es menciona a la informació del context que es l'home de la capa.                           | ca     | deepseek-v1 | all-minilm | 3     | 43.43         | 0.02          | 43.41         | 358          | 317          | 675        | 9.83  | 0.0        | La resposta del sistema no menciona Bleeding Gums Murphy com a líder de la L5a.              | 0.248  | 0.752     | 0.738      | 0  | 0     | 0       | 0.119     |
| 2  | Quin instrument toca la Lisa?                    | Saxofon                                     | El seu instrument musical és el saxof.                                                         | ca     | deepseek-v1 | all-minilm | 3     | 37.01         | 2.06          | 34.95         | 356          | 236          | 592        | 9.92  | 8.5        | La resposta és amb prou feina a la correcta, però hi ha un petit error en la transliteració. | 0.330  | 0.680     | 0.626      | 0  | 0     | 0       | 0.079     |
| 3  | Com es diu el gos del Bart?                      | Little Squirt's Helper                      | El context no proporciona un nom específic, però un gos anomenat al llibre de Bart Simpson.    | ca     | deepseek-v1 | all-minilm | 3     | 53.78         | 2.07          | 51.71         | 363          | 391          | 754        | 9.65  | 0.0        | La resposta no es refereix al personatge i no proporciona informació sobre el gos.           | 0.253  | 0.747     | 0.575      | 0  | 0     | 0       | 0.113     |
| 4  | En què treballa el Homer Simpson?                | Inspector de seguretat a la central nuclear | Aquestes fonts no proporcionen detall sobre el treball habitual o actual de Homer Simpson.     | ca     | deepseek-v1 | all-minilm | 3     | 43.46         | 2.06          | 41.41         | 373          | 283          | 658        | 9.36  | 1.5        | La resposta és vàlida i no coincideix amb la correcta.                                       | 0.247  | 0.753     | 0.705      | 0  | 0.095 | 0.095   | 0.288     |
| 5  | En quin episodi coneixen el Homer amb el Baggio? | The Call of the Simpsons (501 ED)           | Aquest fa referència a l'episodi "The Call of the Simpsons", que és la setena de la tempestad. | ca     | deepseek-v1 | all-minilm | 3     | 47.64         | 2.06          | 45.58         | 373          | 314          | 689        | 9.12  | 9.5        | La resposta és correcta però podria ser més específica.                                      | 0.150  | 0.850     | 0.812      | 0  | 0.385 | 0.385   | 0.301     |